

# *Chapter3* 텐서플로2.0 시작하기

## - 딥러닝 기초 -

SeoKyeong University  
Department of Computer Engineering  
Professor. Lee Kwang Yeob



- TensorFlow2.0 설치 결과 보고
- 교재 2장 설명에 따라 CUDA, 아나콘다 환경 설치(GPU 사용)
- colab 활용
- 보고 방법 : 이메일([kylee@skuniv.ac.kr](mailto:kylee@skuniv.ac.kr))로 설치 결과 또는 문제점
- 매주 수업계획서에서 부여되는 [과제] 는 자습 으로 하며 제출하지 않음
- [레포트]로 부여 되는 경우 화일로 제출함
- 교재 내용 이외 자체 제작된 슬라이드 는 강의자료실에 업로드 됨

- 2018년 9월 1일 날씨를 예측한다면?
- 데이터(예측 모델을 만들기 위한 학습 데이터) 필요

- 내년 월별 평균 기온 데이터를 예측한다면?
- **데이터의 모델화** : 데이터 수치를 있는 그대로가 아닌 원리를 생각하는 것

$$y = w_0 + w_1x + w_2x^2 + w_3x^3 + w_4x^4$$

x : 각각의 달 (1, 2, ..., 12)

y : 예상 평균 기온 (ex 20°C)

w : 변경 가능한 파라미터




그림 1-3 월별 평균 기온 데이터






그림 1-4 완전한 곡선으로 예측한 평균 기온

- 곡선이 올바른 기준 : 데이터 오차(Error) 로 판단

- 오차 함수 (error function)

: W로 구성된 함수가 실제 값과 일치하지 않는 정도를 나타내는 함수

- 제곱 오차



$$E = \frac{1}{2} \sum_{n=1}^{12} (y_n - t_n)^2$$

$y$  : 예상 평균 기온 (ex 20°C)

$t_n$  : n월 평균 기온 데이터

- 머신러닝 모델의 3단계

- 주어진 데이터 기반으로 미지의 데이터 예측

$$y = w_0 + w_1x + w_2x^2 + w_3x^3 + w_4x^4$$

- 파라미터의 좋고 나쁨을 판단(오차 함수)

$$E = \frac{1}{2} \sum_{n=1}^{12} (y_n - t_n)^2$$

- 오차 함수를 최소화하도록 파라미터 수정

- $y_n$ 은  $n$ 월 ( $n = 1 \sim 12$ )의 기온을 예측한 결과

$$y_n = w_0 + w_1n + w_2n^2 + w_3n^3 + w_4n^4 = \sum_{m=0}^4 w_m n^m$$

- 예측한 식의 오차함수

$$E(w_0, w_1, w_2, w_3, w_4) = \frac{1}{2} \sum_{n=1}^{12} \left( \sum_{m=0}^4 w_m n^m - t_n \right)^2$$

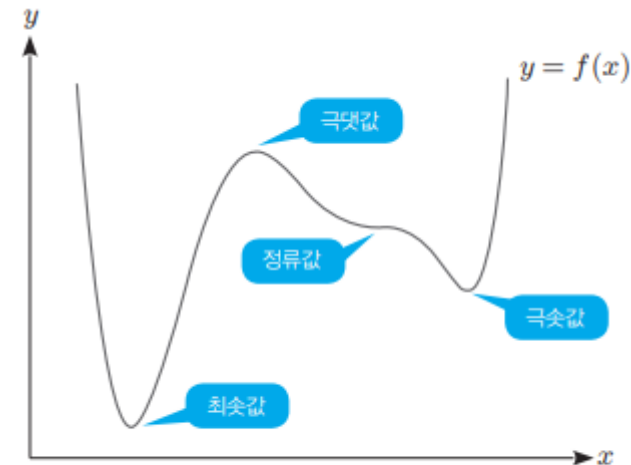


그림 1-13 그래프의 기울기가 0이 되는 지점

- 오차함수가 최소가 된 것이 데이터와 차이가 가장 적음



- 오차함수가 최소가 되도록 파라미터를 수정하기 위해서는 편미분이 필요

- 편미분 : 복수의 변수를 갖는 함수에 대해 특정한 하나의 변수로 미분하는 것

- 2변수 함수의 편미분

- 임의의 함수  $h(x_1, x_2) = \frac{1}{4}(x_1^2 + x_2^2)$

- 함수의 편미분

$$\frac{\partial h}{\partial x_1}(x_1, x_2) = \frac{1}{2}x_1, \quad \frac{\partial h}{\partial x_2}(x_1, x_2) = \frac{1}{2}x_2$$

$$\nabla h(x_1, x_2) = \frac{1}{2} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$




그림 1-14 2변수 함수의 기울기 벡터



## ● 경사 하강법 (gradient descent)

- 오차함수가 최소가 되게 하기 위한 방법
- 현재 위치에서 기울기와 반대방향으로 이동
- 기울기 값을 계속 빼서 기울기가 0이 되도록 한다.
- 값 갱신  $x^{new} = x - \nabla h$





그림 1-14 2변수 함수의 기울기 벡터




그림 1-15 경사 하강법으로 최솟값에 가까워지는 모습

## ● 학습률(learning rate)

- 경우에 따라 최솟값을 지나쳐 발산하는 경우가 발생




그림 1-16 경사 하강법에 의한 두 종류의 이동 예

- 학습률(learning rate)

- 발산을 방지하기 위해 이동량을 적당히 줄이는 파라미터
- 클 수록 발산할 확률이 높아진다.
- 작을수록 오차함수가 최소화되기까지 시간이 더 걸린다.

$$x^{new} = x - \epsilon \nabla h$$

- 트레이닝 세트(Training Set)

- 파라미터 w들을 최적화하기 위해 사용하는 데이터 집합

- 예비 검사 데이터로 감염을 예측하는 예
  - 직선을 통해 경계를 나타내고 감염일 확률을 구한다.

## 머신러닝 모델의 3단계 중 1단계

- 경계 :  $f(x_1, x_2) = w_0 + w_1x_1 + w_2x_2 = 0$
- 감염 확률 :  $P(x_1, x_2) = \sigma(f(x_1, x_2))$

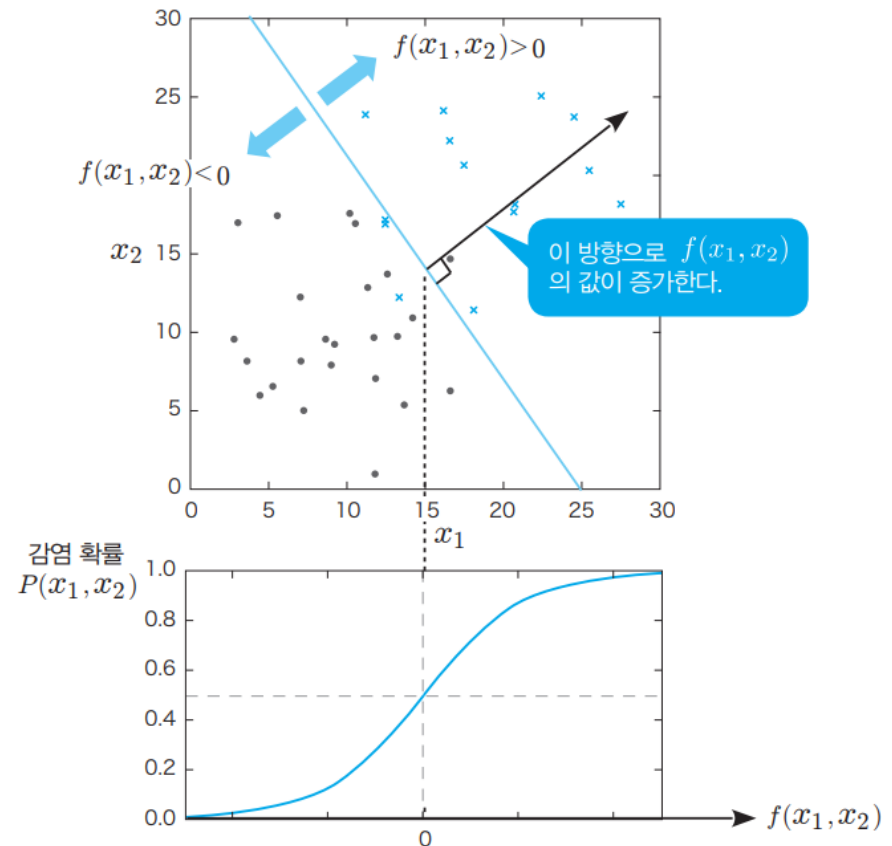


그림 1-6 직선을 이용한 분류와 감염 확률로의 변환

- 직선의 방정식으로는 해결할 수 없는 문제
  - 데이터가 직선의 경계를 갖지 않을 때
  - 입력 데이터( $x$ )가 여러 개일 때 (차원의 수 증가)

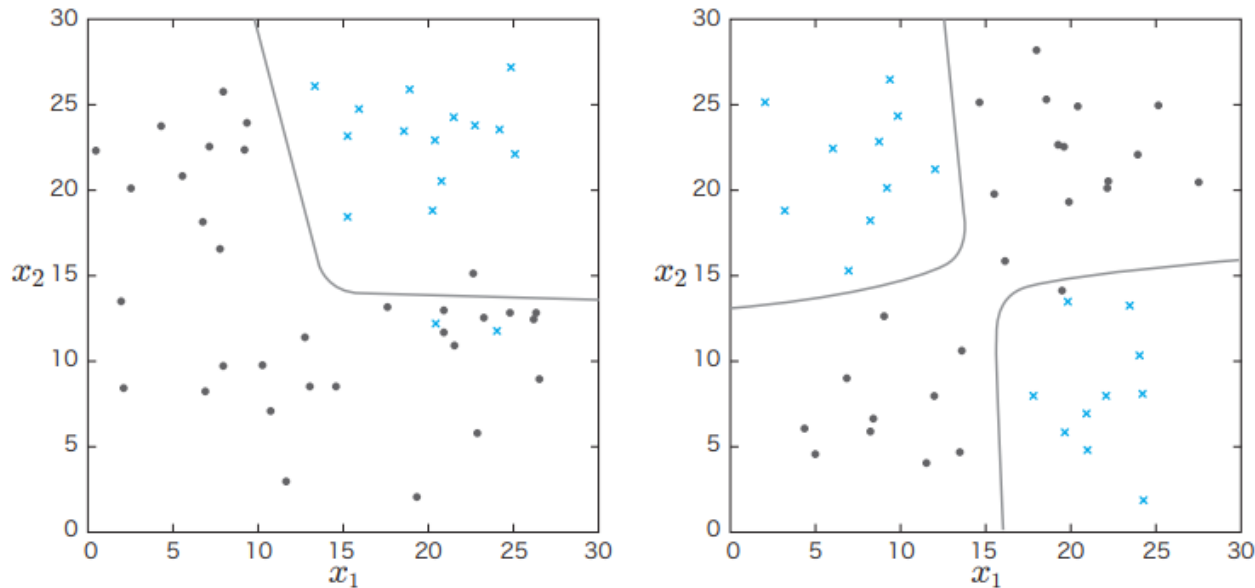


그림 1-7 보다 복잡한 데이터 배치의 예

- 뉴런 (Neuron) 또는 노드 (Node)

- 신경망을 구성하는 최소 유닛





그림 1-8 단일 노드로 된 신경망

- 신경망 (Neural Network)

- 여러 뉴런을 다층으로 중첩한 것



$$f_1(x_1, x_2) = w_{10} + w_{11}x_1 + w_{12}x_2$$

$$f_2(x_1, x_2) = w_{20} + w_{21}x_1 + w_{22}x_2$$

$$f(z_1, z_2) = w_0 + w_1z_1 + w_2z_2$$

그림 1-9 2계층 노드로 된 신경망




그림 1-10 2계층 신경망에 의한 분할 예

## • 더욱 더 복잡한 신경망

- 복잡한 경계(함수)를 표현할 수 있다
- 계산이 많이 필요해진다
- 눈에 보이지 않는 데이터의 특성을 감으로 찾아야한다. => 딥러닝(deep learning) 등장

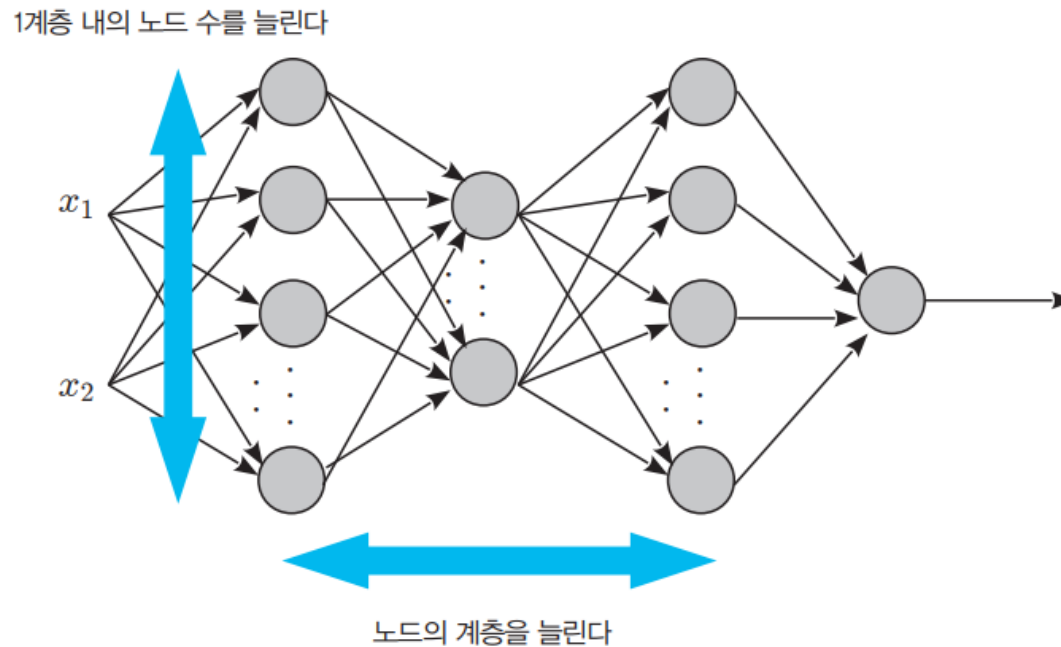




그림 1-11 보다 복잡한 다층 신경망의 예


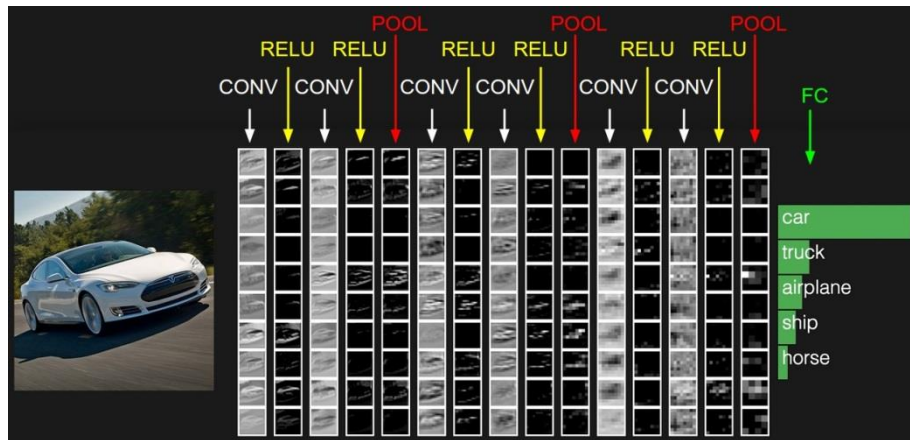


- 다층 신경망을 이용한 머신러닝
  - 노드에 특별한 역할이나 노드 간의 연결방식을 다양하게 연구한 것
- 예시
  - 합성곱 신경망(Convolutional Neural Network)
    - 합성곱 필터(Convolutional filter)
    - 풀링 계층(pooling layer)
  - 순환 신경망(RNN, Recurrent Neural Network)

- 합성곱 신경망(Convolutional Neural Network)



Convolution with horizontal and vertical strides = 1



- 순환 신경망(Recurrent Neural Network)

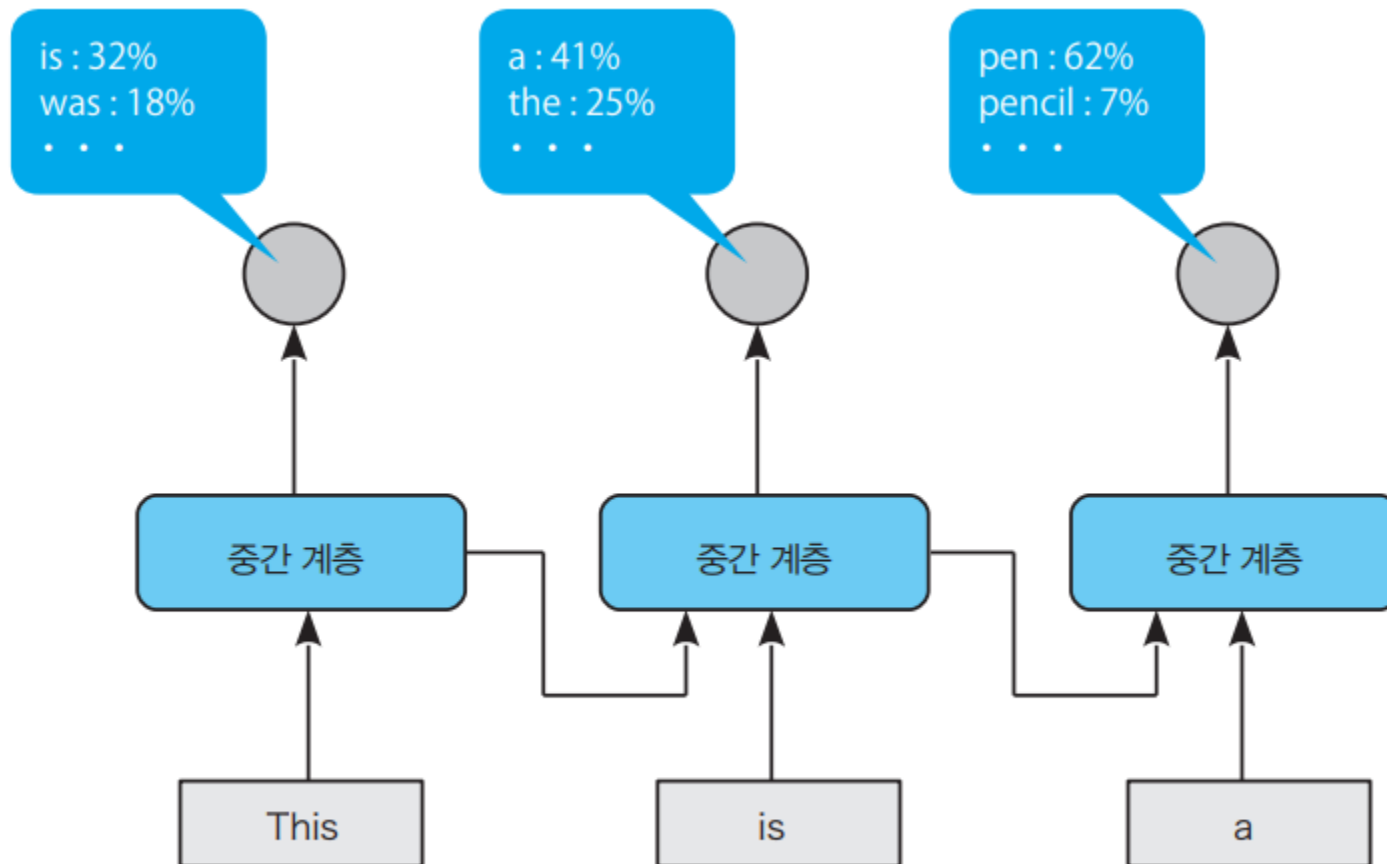


그림 1-12 RNN으로 다음 단어를 예측하는 예